


Uvod u mašinsko učenje

- Šta je mašinsko učenje
 - Primene mašinskog učenja
- Osnovni pojmovi
 - Model, obeležje i uzorak
 - Razvojni ciklus sistema za mašinsko učenje
 - Vrste problema u mašinskom učenju
 - Nadgledano i nenadgledano učenje
- Klasifikacija
 - Primer: razvoj sistema za klasifikaciju
- Regresija
- Detaljniji pregled sadržaja kursa




Uvod u mašinsko učenje

- **Uzorak** = objekat iz realnog sveta koji poseduje određena svojstva (obeležja)
 - Uzorak pripada određenoj **populaciji**
- Ciljevi:
 - Sticanje *znanja* o podacima
 - Donošenje *odluka* na osnovu podataka ili predviđanje njihovog ponašanja u budućnosti
- Razvoj računara ubrzao je praktične primene, koje su dovele i do novih teorijskih otkrića




Primeri mašinskog učenja

- Mašinska vizija
 - Vizuelna inspekcija objekata
 - Detekcija ciljeva na zemlji
- Optičko prepoznavanje karaktera
 - Automatsko sortiranje pošte, obrada čekova
 - Automatsko prepoznavanje registarskih tablica
 - Skeniranje knjiga, asistivne tehnologije
- Govorna interakcija čovek-mašina
 - Prepoznavanje govora
 - Virtuelni asistenti
- Kompjuterski potpomognuta dijagnostika
 - Analiza medicinske slike, EEG i EKG signala
 - Namenjena da pomogne lekarima, ne da ih zameni
 - Primer: mamografija
 - 10–30% lažnih negativa
 - 2/3 bi moglo da se spreči odgovarajućom analizom
- Sistemi za automatsko davanje preporuka
 - Amazon, IMDb, Netflix...



Kada se koristi mašinsko učenje

- Ako su količine podataka izuzetno velike
 - Skupovi podataka nastali automatizacijom (nadzorne kamere, elektronski medicinski kartoni...)
 - Podaci direktno prikupljeni sa interneta („klikovi“, „lajkovi“...)
- Ako su u pitanju sistemi koje nije moguće isprogramirati na klasičan način
 - Ako se problem menja u vremenu i zavisi od okoline (autonomna vozila)
 - Ako ni nama nije jasno kako nešto radimo (govorna komunikacija)
- Mnogim konceptima mašinskog učenja odgovaraju koncepti koji se susreću kod ljudskog učenja



Dva zanimljiva primera

■ Watson (2011)

- ❑ Računar sposoban da odgovara na pitanja postavljena prirodnim jezikom
- ❑ Razvijen od strane IBM i posebno prilagođen za potrebe takmičenja u kvizu *Jeopardy!*
- ❑ Pobedio finaliste Brada Ruttera i Kena Jenningsa i osvojio prvu nagradu od 1.000.000 \$
- ❑ Tokom kviza imao na raspolaganju, između ostalog, kompletnu Wikipediju, ali ne i pristup internetu



■ Heritage Healthprize (2012)

- ❑ Izazov s ciljem razvoja sistema koji će na osnovu medicinske dokumentacije najtačnije identifikovati ljude koji će u narednih godinu dana biti primljeni na bolničko lečenje
- ❑ Nagrada od 3.000.000 \$ zapravo je predstavljala investiciju u razvoj algoritama mašinskog učenja i sistema za predikciju

A graphic for the Heritage Healthprize competition. It features a stylized ECG line with red and blue segments. Below the line, the text reads: 'Improve Healthcare, Win \$3,000,000.' and 'COMPETITION GOAL: Identify patients who will be admitted to a hospital within the next year, using historical claims data.' The URL 'http://www.heritagehealthprize.com/c/hhp' is at the bottom.

Improve Healthcare, Win \$3,000,000.

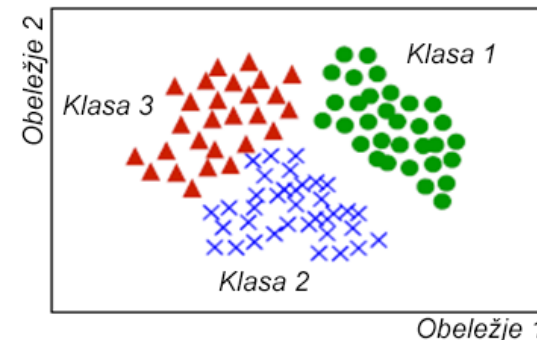

COMPETITION GOAL
Identify patients who will be admitted to a hospital within the next year, using historical claims data.

<http://www.heritagehealthprize.com/c/hhp>

Obeležja i uzorci

■ Obeležje

- **Obeležje** je bilo koji merljiv aspekt, osobina ili karakteristika nekog objekta
 - Obeležje može biti simboličko (npr. boja) ili numeričko (npr. visina ili težina)
- Definicije
 - Kombinacija d obeležja predstavlja se kao d -dimezionalna vektor-kolona (**vektor obeležja**)
 - d -dimenzionalni prostor definisan vektorom obeležja naziva se **prostor obeležja**
 - Objekti su predstavljeni kao tačke u prostoru obeležja
 - Grafički prikaz ovakvih tačaka se naziva **dijagram rasejanja** (*scatter plot*)




■ Uzorak


- **Uzorak** je određena kombinacija osobina ili obeležja karakterističnih za određeni objekat
- U problemu klasifikacije uzoraka jedan uzorak je predstavljen parom promenljivih $\{\mathbf{x}, \omega\}$, gde je:
 - \mathbf{x} skup vrednosti obeležja (vektor obeležja)
 - ω klasa kojoj uzorak pripada (oznaka klase)

Primer: obeležja u problemu klasifikacije

- Šta odlikuje jedan „dobar“ vektor obeležja?
 - Kvalitet vektora obeležja je u vezi sa njegovom sposobnošću da razdvoji primerke koji pripadaju različitim klasama
 - Primerci iz iste klase treba da imaju slične vrednosti vektora obeležja
 - Primerci iz različitih klasa treba da imaju različite vrednosti vektora obeležja




„Dobra“ obeležja




„Loša“ obeležja


- Na šta još može uticati izbor određenog skupa obeležja




Linearna separabilnost



Nelinearna separabilnost



Jaka korelisanost



Multimodalnost

Vrste predikcionih problema

■ Klasifikacija


- Pridruživanje objekata klasama
- Izlaz sistema je oznaka klase (broj klasa je konačan)
 - Označavanje proizvoda (dobar/loš) na testu provere kvaliteta
 - Detekcija spama

■ Regresija

- Uopštenje problema klasifikacije
- Izlaz sistema za mašinsko učenje je realan broj
 - Procena početne cene (npr. nekretnine ili vozila)
 - Predviđanje vrednosti akcija na osnovu vrednosti u prošlosti i berzanskih indikatora

■ Klasterizacija

- Grupisanje sličnih objekata
- Grupisanje može biti hijerarhijsko
 - Kategorizacija živih bića, novinskih tekstova



Nadgledano i nenadgledano učenje

■ Klasifikacija i regresija predstavljaju primere **nadgledanog učenja**


- Vrednost izlazne veličine tj. „oznake“ (npr. pripadnost određenoj klasi), za svaki uzorak u skupu za obuku unapred je poznata

■ Klasterizacija predstavlja primer **nenadgledanog učenja**


- Nije unapred poznato koji klasteri postoje, a često ni koliko ih ima
- Uzorci nemaju „oznake“
- Još neki primeri nenadgledanog učenja su neke metode redukcije dimenzionalnosti kao i nenadgledano učenje reprezentacije podataka

■ Pored ove dve grupe postoji i **podstaknuto učenje** (*reinforcement learning*)

- bavi se problemom pronalaženja adekvatne akcije u datoj situaciji, u cilju maksimizacije nagrade, na osnovu interakcije s okolinom kroz pokušaje i greške
- zasniva se na postizanju ravnoteže između istraživanja i korišćenja otkrivenih znanja



nadgledano učenje



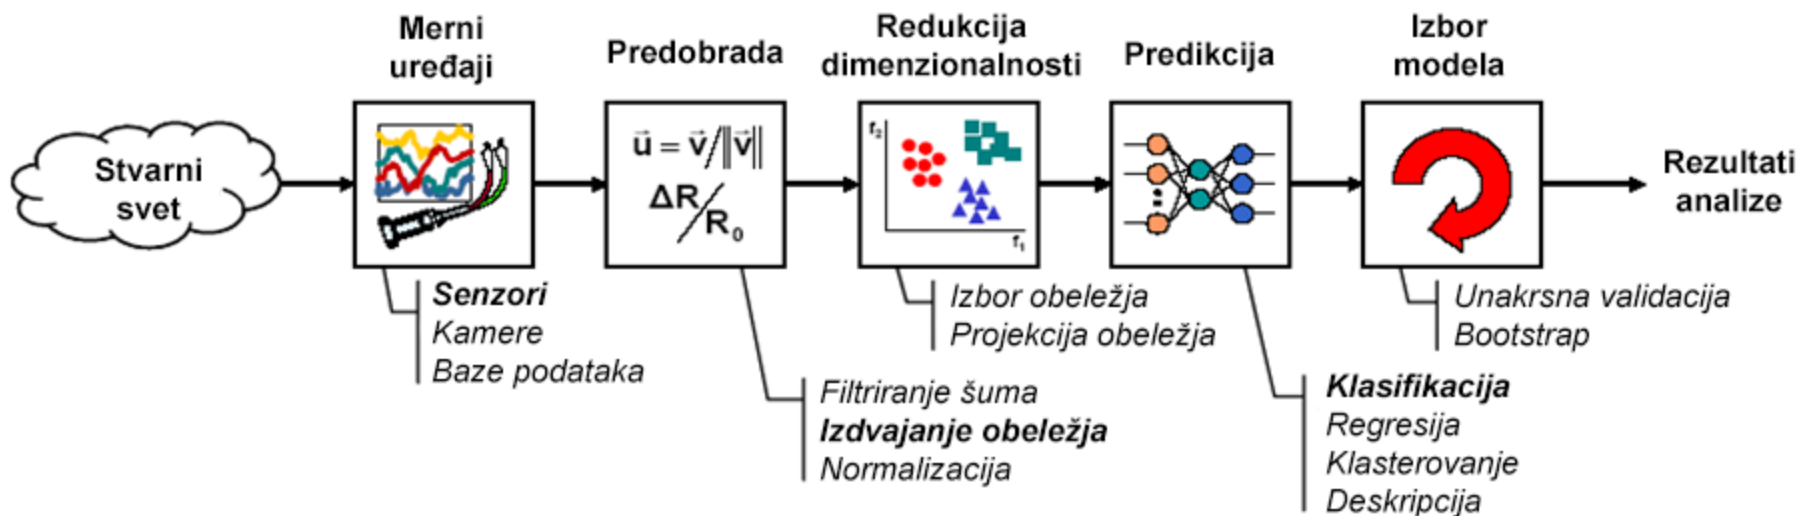
nenadgledano učenje

Rano i kasno učenje

- Metode **nadgledanog učenja** mogu se načelno podeliti na metode ranog učenja (eng. *eager learning*) i metode kasnog učenja (eng. *lazy learning*)
- Metode sa **ranim učenjem**
 - Uzorci za obuku ne čuvaju se u izvornom obliku, već se prevode u odgovarajući *model*, koji predstavlja njihov komprimovan opis
 - Nakon dobijanja modela skup za obuku može se odbaciti jer više nije potreban
 - Klasifikacija/regresija za nepoznate uzorke vrši se isključivo na osnovu kreiranog modela
 - Obuka može biti izuzetno složena, ali je klasifikacija/regresija računski mnogo manje zahtevna
 - Postoji opasnost od loše formiranog modela
- Metode sa **kasnim učenjem**
 - Obrada uzoraka za obuku odlaže se do trenutka kada se javi zahtev za klasifikacijom ili regresijom za nepoznati uzorak, dok klasične obuke često i nema
 - U odgovoru na zahtev za klasifikacijom/regresijom koristi se celokupni skup za obuku
 - Ove metode imaju vrlo visoke zahteve za memorijskim prostorom i računski su veoma zahtevne u toku klasifikacije/regresije
 - Nakon klasifikacije/regresije svi rezultati do kojih se došlo odbacuju se i sve se radi iznova za svaki naredni zahtev, bez obzira koliko je već puta urađena klasifikacija/regresija

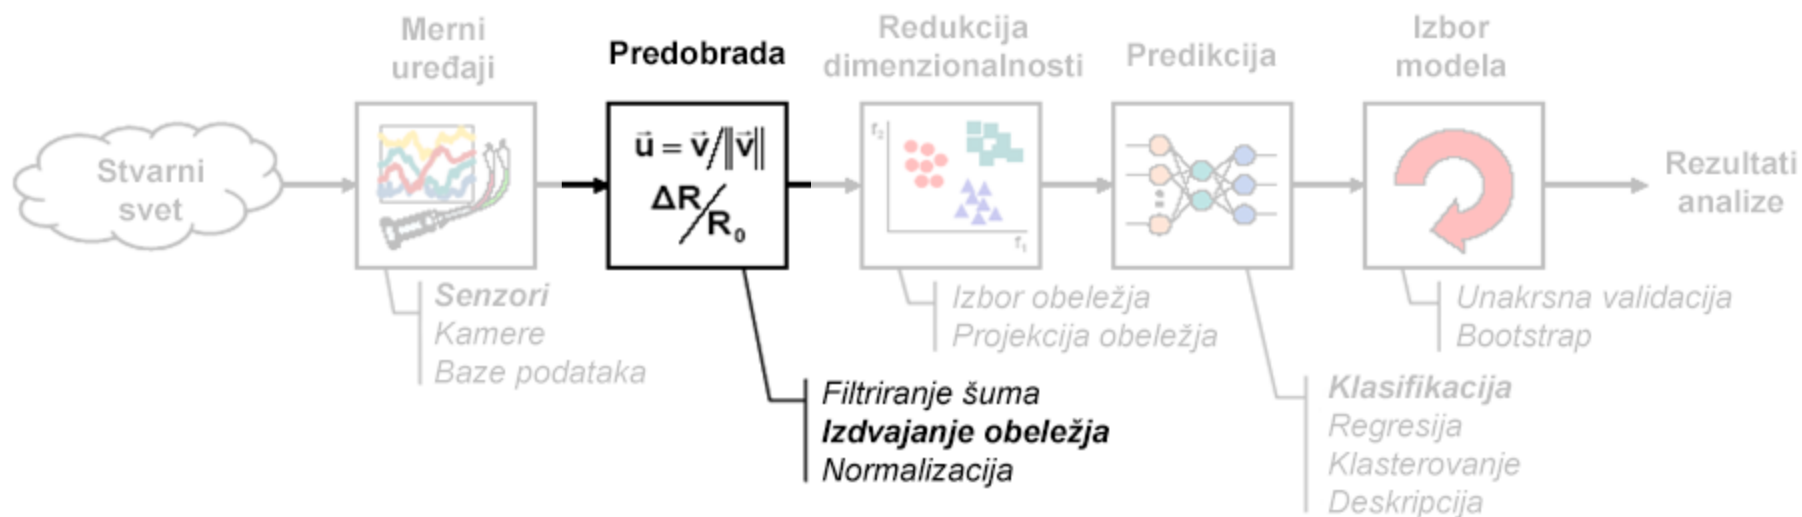
Komponente sistema za mašinsko učenje

- Osnovni sistem za mašinsko učenje sadrži
 - Senzore
 - Mehanizam za predobradu podataka
 - Mehanizam za izdvajanje obeležja (ručno ili automatsko)
 - Algoritam za donošenje odluke (npr. klasifikacija ili regresija)
 - Skup klasifikovanih ili već opisanih uzoraka (skup za obuku)



Predobrada podataka

- Podaci sadrže **šum** koji se možda može ukloniti
- Potrebno je **identifikovati relevantna obeležja**
- Potrebno je **normalizovati obeležja**, odnosno ujednačiti opsege njihovih vrednosti



Normalizacija podataka

- Potrebno je ujednačiti opsege vrednosti pojedinih obeležja
- Dva najčešće korišćena pristupa

□ Z- normalizacija

$$x' = \frac{x - \hat{\mu}}{\hat{\sigma}}$$

$\hat{\mu}$ – uzoračka srednja vrednost
 $\hat{\sigma}$ – uzoračka standardna devijacija

- Obeležje normalizovano na ovaj način ima nultu srednju vrednost i jediničnu standardnu devijaciju

□ Normalizacija opsega

$$x' = \frac{x - \min\{x_i\}}{\max\{x_i\} - \min\{x_i\}}$$

- Obeležje normalizovano na ovaj način ima vrednosti u opsegu [0, 1]

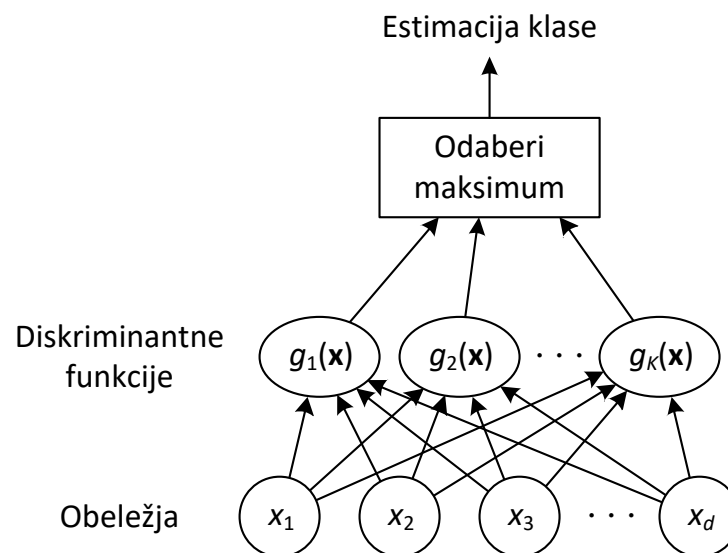

STAROST	PRIHOD
37	42.000
47	94.500
42	28.000
53	61.000
29	138.000
28	48.500
41	170.500
50	89.500

Razvojni ciklus sistema za mašinsko učenje

- Prikupljanje podataka
 - Često je, što se vremena tiče, najzahtevnija stavka u razvoju sistema za mašinsko učenje
 - Koji je dovoljan broj primeraka?
- Izbor obeležja
 - Veoma bitan za uspešno rešavanje problema mašinskog učenja
 - Zahteva *predznanje*
- Evaluacija
 - Koliko je obučeni model uspešan u svom zadatku
 - U praksi je značajno proceniti kako bi se model ponašao **na novim podacima**
- Izbor modela
 - Podešavanje hiperparametara modela
- Obuka
 - Prilagoditi neinicijalizovan model prikupljenim podacima, na osnovu izabranog skupa obeležja

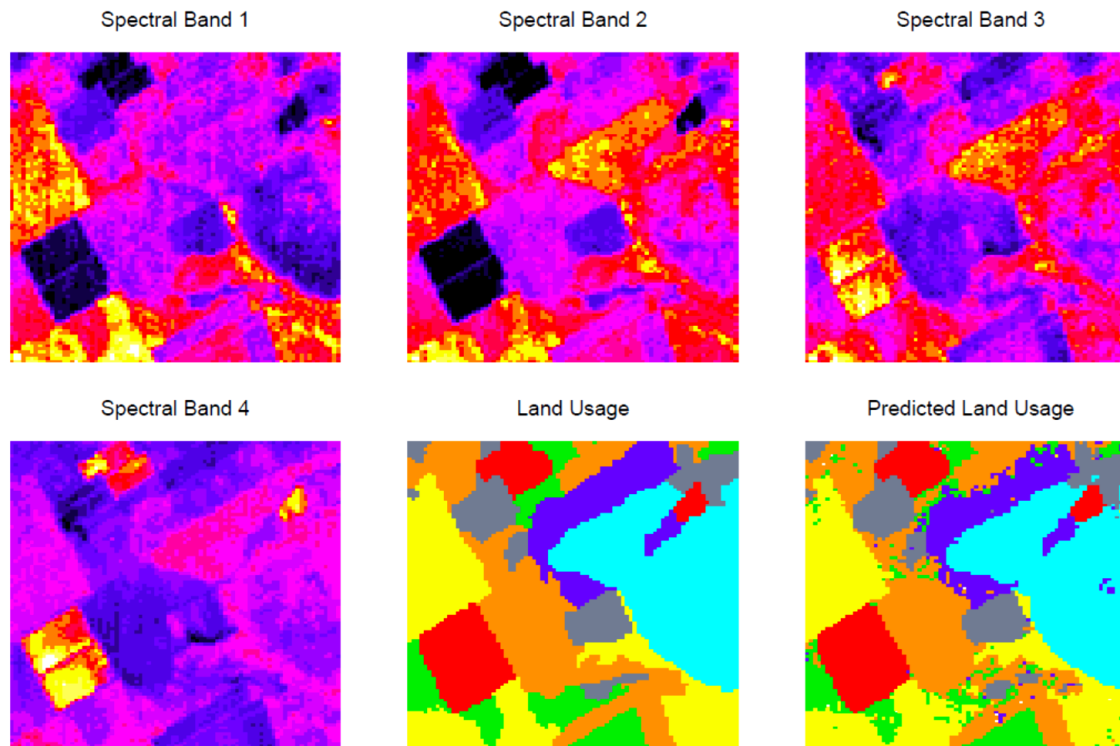
Klasifikacija

- Zadatak klasifikatora je da dodeli uzorak predstavljen vektorom obeležja \mathbf{x} odgovarajućoj klasi
 - ovo je ekvivalentno podeli prostora obeležja na klasne regione odlučivanja
 - Granice između regiona odlučivanja se nazivaju **granicama odlučivanja**
- Klasifikator se može predstaviti kao skup diskriminantnih funkcija
 - Klasifikator dodeljuje vektor obeležja \mathbf{x} klasi ω_i ako je $g_i(\mathbf{x}) > g_j(\mathbf{x})$ za svako $j \neq i$




Primer: klasifikacija piksela u LANDSAT slici

- Klasifikacija piksela prema nameni (kultura koja se uzgaja)
- Snimanje u 4 frekvencijska opsega (opsega talasnih dužina)
 - Snima se 3×3 piksela oko datog piksela, pa se dobija 36 dimenzija



Primer: razvoj sistema za klasifikaciju


- Razmotrimo sledeći scenario:
 - Fabrika za preradu ribe želi da automatizuje proces razvrstavanja ribe na ulazu u proces prerade (losos ili brancin)
 - Automatizovani sistem sastoji se od:
 - pokretne trake kojom se dovodi sveža riba
 - dve pokretne trake za odvođenje razvrstane ribe
 - robotske ruke (*pick-and-place*)
 - sistema za mašinsku viziju sa CCD kamerom
 - računara koji analizira sliku sa kamere i upravlja robotskom rukom



Primer: razvoj sistema za klasifikaciju


■ Senzor

- ❑ Kamera snima ribu koja ulazi u deo za razvrstavanje




■ Predobrada

- ❑ Algoritmi za obradu slike
 - prilagođavanje prosečnog nivoa osvetljaja
 - segmentacija za odvajanje ribe od pozadine (na slici)



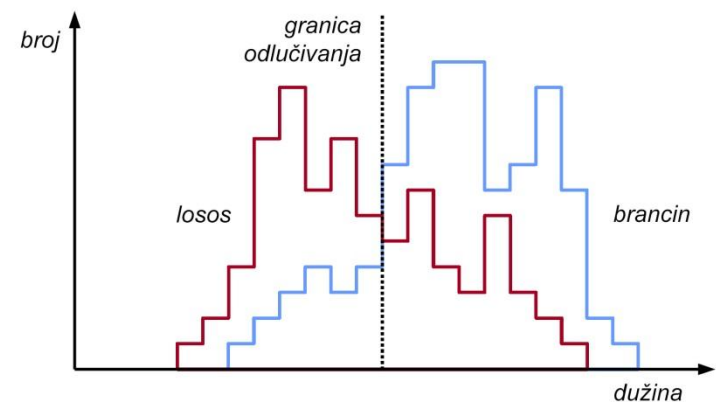
■ Izdvajanje obeležja

- ❑ Pretpostavimo da je u proseku brancin veći od lososa
 - Na osnovu segmentirane slike proceniti koliko je riba dugačka




■ Klasifikacija

- ❑ Sakupimo skup primeraka obe vrste
- ❑ Izračunamo histogram dužine ribe za obe klase
- ❑ Odrediti granicu odlučivanja (prag) pri kome je minimizovana greška klasifikacije
- ❑ Procenjujemo da je verovatnoća greške klasifikatora razočaravajućih 40%
- ❑ **Šta uraditi dalje?**




Primer: razvoj sistema za klasifikaciju

- Poboljšanje performansi našeg sistema za mašinsko učenje
 - U nameri da postignemo tačnost od 95%, ispitujeemo i druga obeležja (širina, površina, položaj očiju u odnosu na usta...), ali dolazimo samo do zaključka da ni ona nisu dovoljno diskriminativna
 - Ipak, nalazimo jedno „dobro“ obeležje: prosečan intenzitet piksela krljušti

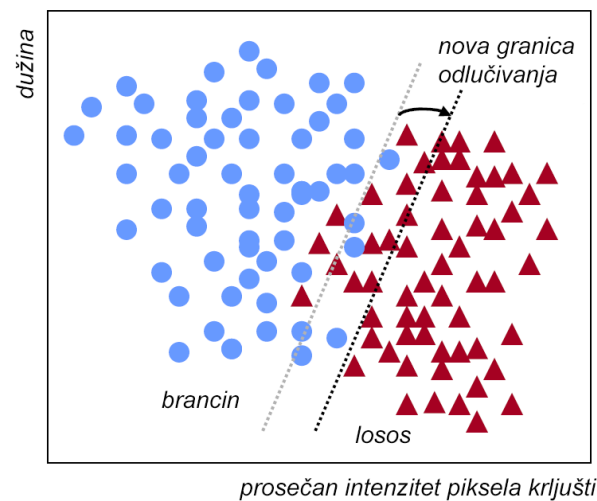
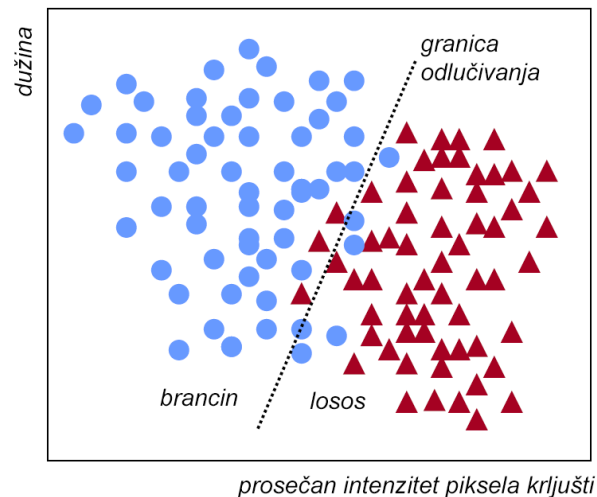


- Kombinujemo dužinu ribe i prosečan intenzitet piksela krljušti da povećamo separabilnost klasa (dodavanje obeležja je generalno dobar pristup)
- Dobijamo tačnost klasifikacije od 95.7%



Primer: razvoj sistema za klasifikaciju


- Stepen pogrešne klasifikacije i cena
 - Naš linearni klasifikator je napravljen tako da minimizuje ukupan procenat pogrešno klasifikovanih objekata
 - Je li to najbolja strategija u našem primeru fabrike za preradu ribe?
 - **Cena** (pogrešnog) klasifikovanja lososa kao brancina jeste da će kupac ponekad naići na ukusnog lososa u pakovanju brancina (a losos je po pravilu skuplji)
 - **Cena** (pogrešnog) klasifikovanja brancina kao lososa jeste kupac koji je nezadovoljan jer je dobio brancina po ceni lososa
 - Intuitivno, dobra je ideja podesiti granicu odlučivanja *tako da se ova cena minimizuje*



Primer: razvoj sistema za klasifikaciju

■ Problem generalizacije

- Stepen ispravne klasifikacije našeg linearnog klasifikatora (95.7%) zadovoljio je specifikacije, ali mi verujemo da možemo još da podignemo performanse sistema
 - Zbog toga formiramo vrlo kompleksnu neuronsku mrežu i ostvarimo impresivan stepen ispravne klasifikacije od preko 99% sa granicom odlučivanja prikazanom na slici
- Zadovoljni svojim klasifikatorom, uradimo integraciju sistema i isporučimo ga fabrici za preradu ribe
 - Nakon nekoliko dana, direktor fabrike zove da se žali da sistem u proseku pogreši u klasifikaciji svake četvrte ribe
 - *Zašto?*



Natprilagođenje skupu za obuku (*overfitting*)

- Natprilagođenje je neizbežno ako se evaluacija modela vrši na istom skupu na kom je model i obučen, pa se to i izbegava
- Do natprilagođenja može doći i ako je model suviše kompleksan za dati skup za obuku
 - Ovakav model ne konstatuje samo razlike između klasa (što bi bilo dobro) već i irelevantne razlike unutar pojedinih klasa, odnosno, irelevantna obeležja pojedinih uzoraka unutar klasa
- Natprilagođeni model gubi sposobnost *generalizacije* i loše se ponaša sa potpuno novim podacima (što je praktični scenario)
- Natprilagođenje se može izbeći na više načina
 - Usvajanjem modela čija složenost odgovara veličini i složenosti skupa za obuku
 - Korišćenjem posebnih tehnika za sprečavanje natprilagođenja (regularizacija)
 - Ako se obuka modela (podešavanje njegovih parametara) vrši kroz iterativnu proceduru, prekidanjem obuke na vreme
- U svakom slučaju, procenu tačnosti modela treba vršiti **na novim podacima**

Regresija

- Zadatak regresora je da za konkretan uzorak opisan vektorom obeležja \mathbf{x} predvidi vrednost određene kontinualne promenljive (*realan broj*)
 - Primeri: visina plate, optimalna cena izdavanja ili početna cena prodaje
- Kao i klasifikacija, i regresija je problem **nadgledanog učenja**, što znači da se sistem obučava na uzorcima koji su opisani vektorima obeležja \mathbf{x} , ali i vrednošću izlazne promenljive y
 - Promenljiva y ne mora biti stvarno kontinualna, dovoljno je da bude pogodno posmatrati je kao kontinualnu

Primer: šta su od navedenog problemi klasifikacije, a šta regresije?


- Imate velike zalihe jedne vrste robe i želite da predvidite koliko komada ćete prodati u naredna tri meseca
- Želite da vaš softver prođe kroz račune vaših klijenata i za svaki od njih pruži obaveštenje da li je hakovan
- Na osnovu raspoložive medicinske dokumentacije želite da predvidite očekivani životni vek za svakog pacijenta iz određene grupe

Primer: linearna regresija (1 dimenzija)

- Zadatak je da se na osnovu vrednosti realne promenljive x predvidi vrednost realne promenljive t
 - U ovom primeru podaci su generisani veštački tako što je na poznatu sinusoidu dodata slučajna vrednost (šum):

$$t(x) = 2\pi x + \mathcal{N}(0,1)$$

- Ova veza zapravo nam je nepoznata i **skup za obuku** sistema obuhvata samo uzorke i njihove izlazne vrednosti (x_i, t_i) , $i = 1, 2, \dots, N$
- Cilj je predvideti vrednost izlazne promenljive t za datu vrednost x na osnovu skupa za obuku
- Uz pretpostavku da nam pravi model nije poznat, možemo pokušati da modelujemo ove tačke polinomijalnom funkcijom određenog reda M
$$t(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \dots + w_M x^M$$
 - Problem se svodi na izbor adekvatnog reda modela M i vrednosti koeficijenata w_i





Primer: linearna regresija (1 dimenzija)

$$t(x, \mathbf{w}) = w_0 + w_1 x + w_2 x^2 + \dots + w_M x^M$$

- Red polinoma M određuje složenost modela
- $t(x, \mathbf{w})$ je nelinearna funkcija x , ali je *linearna funkcija nepoznatih koeficijenata w_i* – i zato se ovaj tip modela i dalje smatra linearnim
- Ako bi red modela M bio poznat, problem bi se sveo na definisanje **funkcije greške** (mere odstupanja modela od stvarnih vrednosti) i njenu minimizaciju
 - Obično se kao funkcija greške koristi srednje kvadratno odstupanje predviđenih vrednosti od tačnih






$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (t(x_n, \mathbf{w}) - t_n)^2$$

- Traži se \mathbf{w}^* za koje je $E(\mathbf{w})$ minimalno, pri čemu je $E(\mathbf{w})$ kvadratna funkcija w_i
- To se rešava izjednačavanjem $\partial E(\mathbf{w}) / \partial w_i$ sa 0



Primer: linearna regresija (1 dimenzija)




- Važan korak je adekvatno **određivanje reda modela M** , koji određuje njegovu složenost
 - Ovaj korak naziva se i selekcijom modela
- Suviše jednostavan model neće moći da nauči sve što bi mogao da nauči iz datih podataka
- Suviše složen model natprilagodiće se skupu za obuku i mnogo će grešiti na novim podacima



- Potrebno je evaluirati svaki model na novim podacima i odabrati najbolji
 - U ovom primeru nije problem veštački generisati nove podatke, ali u praksi moramo podeliti postojeće podatke na **skup za obuku** i **skup za testiranje**

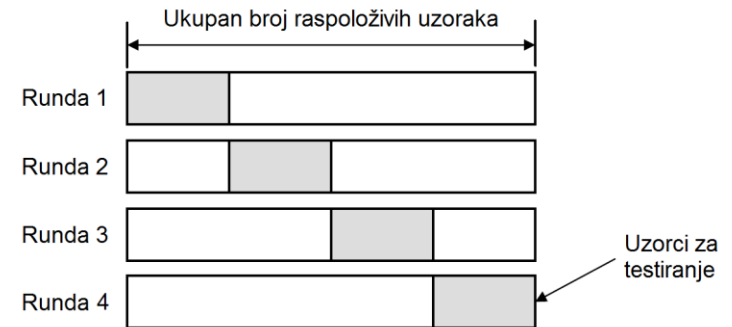
Primer: linearna regresija (1 dimenzija)

- Sa porastom reda modela M svakako opada greška na skupu za obuku, ali za preveliko M greška na skupu za testiranje počinje da *raste*
- Optimalno M biće ono za koje je greška na *skupu za testiranje* minimalna
- Pokazuje se da ako je skup za obuku veći, mogu se koristiti i složeniji, moćniji modeli
- Tehnika koja može pomoći u sprečavanju natprilagođenja je **regularizacija**
 - Funkcija greške modifikuje se dodavanjem regularizacionog člana čiji je cilj da ograniči vrednosti koeficijenata w_i i time spreči suviše dinamično ponašanje $t(x, \mathbf{w})$
$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (t(x_n, \mathbf{w}) - t_n)^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2, \quad \|\mathbf{w}\|^2 = \mathbf{w}^T \mathbf{w} = w_0^2 + w_1^2 + \dots + w_M^2$$
 - Optimalna vrednost λ mora se odrediti kao i vrednost M – na nezavisnom skupu




Teme kojima će se kurs baviti

- **Validacioni postupci**
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- **Linearna i logistička regresija**
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- **Bayesova teorija odlučivanja**
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- **Kvadratni klasifikatori**
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- **Parametarska estimacija gustine raspodele verovatnoće (GRV)**
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- **Estimacija GRV pomoću kernela**
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)





Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- **Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)**
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- **Klasifikaciona i regresiona stabla**
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)



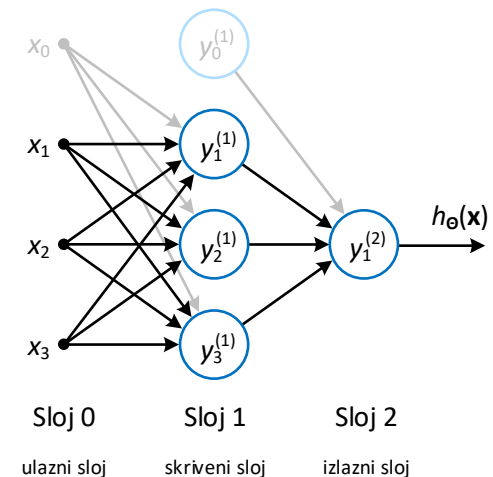
Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- **Linearna klasifikacija i perceptronsko učenje**
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- **Uvod u neuronske mreže**
- Metode na bazi vektora nosača
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)




Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- **Metode na bazi vektora nosača**
- Klasterizacija
- Redukcija dimenzionalnosti (PCA i LDA)



Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- **Klasterizacija**
- Redukcija dimenzionalnosti (PCA i LDA)



Teme kojima će se kurs baviti

- Validacioni postupci
- Linearna i logistička regresija
- Bayesova teorija odlučivanja
- Kvadratni klasifikatori
- Parametarska estimacija gustine raspodele verovatnoće (GRV)
- Estimacija GRV pomoću kernela
- Estimacija GRV i klasifikacija metodom k najbližih suseda (k NN)
- Klasifikaciona i regresiona stabla
- Linearna klasifikacija i perceptronsko učenje
- Uvod u neuronske mreže
- Metode na bazi vektora nosača
- Klasterizacija
- **Redukcija dimenzionalnosti (PCA i LDA)**

