

# Bayesova teorija odlučivanja

- Teorijski osnovi klasifikacije
  - LR test
  - Verovatnoća greške
  - Bayesov rizik
  - Bayesov, MAP i ML kriterijum
  - Odlučivanje kada postoji više klasa
  - Diskriminantne funkcije

# Bayesova teorema u problemu klasifikacije

- Kod problema klasifikacije, Bayesova teorema se može izraziti kao:

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{\sum_{j=1}^K p(\mathbf{x} | \omega_j)P(\omega_j)}$$

pri čemu je  $\omega_j$   $j$ -ta klasa, a  $\mathbf{x}$  vektor obeležja

- $P(\omega_j)$  Apriorna verovatnoća klase  $\omega_j$
- $P(\omega_j | \mathbf{x})$  Aposteriorna verovatnoća klase  $\omega_j$  ako je data opservacija  $\mathbf{x}$
- $p(\mathbf{x} | \omega_j)$  Izglednost/verodostojnost opservacije  $\mathbf{x}$  u klasi  $\omega_j$
- $p(\mathbf{x})$  Normalizaciona konstanta


# Bayesova teorema u problemu klasifikacije

- Kod problema klasifikacije, Bayesova teorema se može izraziti kao:

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{\sum_{j=1}^K p(\mathbf{x} | \omega_j)P(\omega_j)}$$

pri čemu je  $\omega_j$   $j$ -ta klasa, a  $\mathbf{x}$  vektor obeležja

- $P(\omega_j)$       **Apriorna verovatnoća klase  $\omega_j$**
- $P(\omega_j | \mathbf{x})$       Aposteriorna verovatnoća klase  $\omega_j$  ako je data opservacija  $\mathbf{x}$
- $p(\mathbf{x} | \omega_j)$       Izglednost/verodostojnost opservacije  $\mathbf{x}$  u klasi  $\omega_j$
- $p(\mathbf{x})$       Normalizaciona konstanta



- **Apriorna verovatnoća klase  $\omega_j$** 
  - Verovatnoća da uzorak pripada klasi  $\omega_j$  bez obzira na to kako izgleda (bez obzira na  $\mathbf{x}$ )
  - Odslikava naše prethodno znanje o problemu
    - S kojom verovatnoćom se na pokretnoj traci može naći losos ili brancin zavisi od stanja lovišta, sezone...

# Bayesova teorema u problemu klasifikacije

- Kod problema klasifikacije, Bayesova teorema se može izraziti kao:

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{\sum_{j=1}^K p(\mathbf{x} | \omega_j)P(\omega_j)}$$

pri čemu je  $\omega_j$   $j$ -ta klasa, a  $\mathbf{x}$  vektor obeležja

- $P(\omega_j)$  Apriorna verovatnoća klase  $\omega_j$
- $P(\omega_j | \mathbf{x})$  **Aposteriorna verovatnoća klase  $\omega_j$**  ako je data opservacija  $\mathbf{x}$
- $p(\mathbf{x} | \omega_j)$  Izglednost/verodostojnost opservacije  $\mathbf{x}$  u klasi  $\omega_j$
- $p(\mathbf{x})$  Normalizaciona konstanta



- **Aposteriorna verovatnoća klase  $\omega_j$** 
  - Verovatnoća da uzorak pripada klasi  $\omega_j$  imajući u vidu to kako izgleda (imajući u vidu  $\mathbf{x}$ )
  - Nakon što se registruje (izmeri)  $\mathbf{x}$ , verovatnoća pripadnosti klasi  $\omega_j$  više nije  $P(\omega_j)$  nego  $P(\omega_j | \mathbf{x})$

# Bayesova teorema u problemu klasifikacije

- Kod problema klasifikacije, Bayesova teorema se može izraziti kao:

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{p(\mathbf{x})} = \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{\sum_{j=1}^K p(\mathbf{x} | \omega_j) P(\omega_j)}$$

pri čemu je  $\omega_j$   $j$ -ta klasa, a  $\mathbf{x}$  vektor obeležja

- $P(\omega_j)$  Apriorna verovatnoća klase  $\omega_j$
  - $P(\omega_j | \mathbf{x})$  Aposteriorna verovatnoća klase  $\omega_j$  ako je data opservacija  $\mathbf{x}$
  - $p(\mathbf{x} | \omega_j)$  Izglednost/verodostojnost opservacije  $\mathbf{x}$  u klasi  $\omega_j$
  - $p(\mathbf{x})$  Normalizaciona konstanta
- Tipično pravilo odlučivanja kako dodeliti vektor obeležja klasi jeste **da se izabere klasa  $\omega_j$  sa najvećom verovatnoćom  $P(\omega_j | \mathbf{x})$ :**

$$\hat{\omega} = \arg \max_{\omega_j, j=1,2,\dots,K} P(\omega_j | \mathbf{x}) = \arg \max_{\omega_j, j=1,2,\dots,K} \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{p(\mathbf{x})} = \arg \max_{\omega_j, j=1,2,\dots,K} p(\mathbf{x} | \omega_j) P(\omega_j)$$

- Na ovaj način, intuitivno bираmo klasu koja ima najveće izgleda da je iz nje potekao dati vektor obeležja  $\mathbf{x}$

# Binarna klasifikacija

- Slučaj kada imamo samo dve klase (binarna klasifikacija)

$$P(\omega_1 | \mathbf{x}) \underset{\omega_2}{\overset{\omega_1}{\geq}} P(\omega_2 | \mathbf{x})$$

- Na osnovu Bayesovog pravila to se svodi na:

$$\frac{p(\mathbf{x} | \omega_1)P(\omega_1)}{p(\mathbf{x})} \underset{\omega_2}{\overset{\omega_1}{\geq}} \frac{p(\mathbf{x} | \omega_2)P(\omega_2)}{p(\mathbf{x})}$$

- Pošto  $p(\mathbf{x})$  ne utiče na pravilo odlučivanja, može se eliminisati, i izraz se može napisati u obliku:

$$\Lambda(\mathbf{x}) = \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \underset{\omega_2}{\overset{\omega_1}{\geq}} \frac{P(\omega_2)}{P(\omega_1)}$$

- Količnik  $\Lambda(\mathbf{x})$  se naziva količnik izglednosti (eng. *likelihood ratio*), a odgovarajuće pravilo odlučivanja se naziva *LR test* (test količnika izglednosti)
- Pretpostavka je da su raspodele verovatnoće obeležja u pojedinim klasama i apriorne verovatnoće klasa **poznate**
  - Ako već nisu unapred date, treba ih estimirati na osnovu podataka za obuku

# LR test (primer 1)

- Formulirati pravilo odločivanja prema količniku izglednosti za dve klase čije su apriorne verovatnoće jednake, a gustine raspodele verovatnoća su date izrazima:


$$p(x|\omega_1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-4)^2}{2}}, \quad p(x|\omega_2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-10)^2}{2}}.$$

- Rešenje:

$$\Lambda(x) = \frac{\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-4)^2}{2}}}{\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-10)^2}{2}}} = e^{-\frac{(x-4)^2}{2} + \frac{(x-10)^2}{2}} \underset{\omega_2}{\overset{\omega_1}{\gtrless}} 1$$

$$(x-10)^2 - (x-4)^2 \underset{\omega_2}{\overset{\omega_1}{\gtrless}} 0$$

$$x \underset{\omega_2}{\overset{\omega_1}{\gtrless}} 7$$



## LR test (primer 2)

- Formulisati pravilo odlučivanja prema količniku izglednosti za dve klase za čije apriorne verovatnoće važi  $P(\omega_1) = 2P(\omega_2)$ , a gustine raspodele verovatnoća su date izrazima:

$$p(x|\omega_1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-4)^2}{2}}, \quad p(x|\omega_2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-10)^2}{2}}.$$


- Rešenje:

$$\Lambda(x) = \frac{\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-4)^2}{2}}}{\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-10)^2}{2}}} = e^{-\frac{(x-4)^2}{2} + \frac{(x-10)^2}{2}} \underset{\omega_2}{\overset{\omega_1}{\geq}} \frac{1}{2}$$

$$(x-10)^2 - (x-4)^2 \underset{\omega_2}{\overset{\omega_1}{\geq}} 2 \ln \frac{1}{2}$$

$$x \underset{\omega_2}{\overset{\omega_1}{\geq}} 7 + \frac{\ln 2}{6} \approx 7,12$$

Granica odlučivanja pomera se ka centru raspodele sa manjom apriornom verovatnoćom





# Verovatnoća greške

- Bez obzira na optimalno pravilo odlučivanja, greške su neizbežne
  - Verovatnoća greške opisuje kvalitet performansi pravila odlučivanja
- Na osnovu teoreme totalne verovatnoće, verovatnoća greške jednaka je:


$$P(\text{greška}) = \sum_{i=1}^K P(\text{greška} | \omega_i) P(\omega_i),$$

pri čemu je verovatnoća greške unutar određene klase jednaka:

$$P(\text{greška} | \omega_i) = P(\text{odabrano } \omega_j, j \neq i | \omega_i) = \int_{R_j, j \neq i} p(\mathbf{x} | \omega_i) d\mathbf{x}$$

- U najjednostavnijem slučaju, kada postoje dve klase, verovatnoća greške je:

$$\begin{aligned} P(\text{greška}) &= P(\omega_1)P(\text{greška} | \omega_1) + P(\omega_2)P(\text{greška} | \omega_2) \\ &= P(\omega_1) \underbrace{\int_{R_2} p(\mathbf{x} | \omega_1) d\mathbf{x}}_{\epsilon_1} + P(\omega_2) \underbrace{\int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x}}_{\epsilon_2} \end{aligned}$$



# Bayesov rizik

- U opštem slučaju cena pogrešne klasifikacije uzorka iz klase  $\omega_1$  u klasu  $\omega_2$  nije ista kao kada se uzorak iz klase  $\omega_2$  pogrešno klasifikuje u klasu  $\omega_1$ 
  - Slučaj kada se bolestan čovek proglasi za zdravog opasniji je nego kada se zdrav čovek proglasi za bolesnog
- Ovaj koncept se može formalizovati pomoću *funkcije cene*  $C_{ij}$ 
  - $C_{ij}$  predstavlja cenu izbora klase  $\omega_i$  ako je stvarna klasa  $\omega_j$  (za  $i = j$  obično  $C_{ij} = 0$ )
- *Bayesov rizik* definiše se kao matematičko očekivanje cene:

$$\begin{aligned}\mathfrak{R} = E[C] &= \sum_{i=1}^K \sum_{j=1}^K C_{ij} \cdot P(\text{odabrano } \omega_i \text{ a stvarna klasa je } \omega_j) \\ &= \sum_{i=1}^K \sum_{j=1}^K C_{ij} \cdot P(\mathbf{x} \in R_i | \omega_j) P(\omega_j)\end{aligned}$$

pri čemu:

$$P(\mathbf{x} \in R_i | \omega_j) = \int_{R_i} p(\mathbf{x} | \omega_j) d\mathbf{x}$$

- Kako izgleda pravilo odlučivanja koje minimizuje Bayesov rizik?

# Bayesov rizik (slučaj dve klase)

$$\begin{aligned}\mathfrak{R} = E[C] &= \sum_{i=1}^2 \sum_{j=1}^2 C_{ij} \cdot P(\text{odabrano } \omega_i \text{ a stvarna klasa je } \omega_j) \\&= \sum_{i=1}^2 \sum_{j=1}^2 C_{ij} \cdot P(\mathbf{x} \in R_i | \omega_j) P(\omega_j) \\&= \sum_{i=1}^2 \sum_{j=1}^2 C_{ij} \cdot P(\omega_j) \int_{R_i} p(\mathbf{x} | \omega_j) d\mathbf{x} \\&= C_{11} \cdot P(\omega_1) \int_{R_1} p(\mathbf{x} | \omega_1) d\mathbf{x} + C_{12} \cdot P(\omega_2) \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x} \\&\quad + C_{21} \cdot P(\omega_1) \int_{R_2} p(\mathbf{x} | \omega_1) d\mathbf{x} + C_{22} \cdot P(\omega_2) \int_{R_2} p(\mathbf{x} | \omega_2) d\mathbf{x} \\&= C_{11} \cdot P(\omega_1) \int_{R_1} p(\mathbf{x} | \omega_1) d\mathbf{x} + C_{12} \cdot P(\omega_2) \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x} \\&\quad + C_{21} \cdot P(\omega_1) \left(1 - \int_{R_1} p(\mathbf{x} | \omega_1) d\mathbf{x}\right) + C_{22} \cdot P(\omega_2) \left(1 - \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x}\right) \\&= C_{21} \cdot P(\omega_1) + C_{22} \cdot P(\omega_2) \\&\quad + (C_{12} - C_{22}) P(\omega_2) \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x} - (C_{21} - C_{11}) P(\omega_1) \int_{R_1} p(\mathbf{x} | \omega_1) d\mathbf{x}\end{aligned}$$

- Potrebno je odabrati region odlučivanja kojim se  $\mathfrak{R}$  minimizuje, pri čemu je jasno da sabirci  $C_{21} \cdot P(\omega_1)$  i  $C_{22} \cdot P(\omega_2)$  ne utiču na to

# Bayesov rizik (slučaj dve klase)

$$\hat{R}_1 = \operatorname{argmin}_{R_1} \{\mathfrak{R}\}$$

$$= \operatorname{argmin}_{R_1} \left\{ \int_{R_1} [(C_{12} - C_{22}) P(\omega_2) p(\mathbf{x} | \omega_2) - (C_{21} - C_{11}) P(\omega_1) p(\mathbf{x} | \omega_1)] d\mathbf{x} \right\}$$

$$= \operatorname{argmin}_{R_1} \left\{ \int_{R_1} g(\mathbf{x}) d\mathbf{x} \right\}$$


- Pošto je potrebno minimizovati integral, treba odabrati samo oblasti u kojima  $g(\mathbf{x}) < 0$ :

$$(C_{21} - C_{11}) P(\omega_1) p(\mathbf{x} | \omega_1) \underset{\omega_2}{\overset{\omega_1}{\gtrless}} (C_{12} - C_{22}) P(\omega_2) p(\mathbf{x} | \omega_2)$$

što se ponovo svodi na određenu varijantu LR testa:

$$\frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \underset{\omega_2}{\overset{\omega_1}{\gtrless}} \frac{(C_{12} - C_{22})}{(C_{21} - C_{11})} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

- Dakle, minimizacija Bayesovog rizika takođe se svodi na primenu LR testa



# Bayesov rizik (primer)

- Neka je potrebno izvršiti klasifikaciju u dve klase za koje su raspodele obeležja date sledećim izrazima:


$$p(\mathbf{x}|\omega_1) = \frac{1}{\sqrt{2\pi}\sqrt{3}} e^{-\frac{x^2}{6}}, \quad p(\mathbf{x}|\omega_2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-2)^2}{2}}.$$

Skicirati raspodele obeležja i, uz pretpostavku da je  $P(\omega_1) = P(\omega_2) = 0.5$ ,  $C_{11} = C_{22} = 0$ ,  $C_{12} = 1$  i  $C_{21} = \sqrt{3}$ , odrediti pravilo odlučivanja koje minimizuje Bayesov rizik.

- Rešenje:

$$\Lambda(x) = \frac{\frac{1}{\sqrt{2\pi}\sqrt{3}} e^{-\frac{x^2}{6}}}{\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-2)^2}{2}}} = \frac{1}{\sqrt{3}} e^{-\frac{x^2}{6} + \frac{(x-2)^2}{2}} \underset{\omega_1}{\underset{\omega_2}{\gtrless}} \frac{1}{\sqrt{3}}$$
$$-\frac{x^2}{6} + \frac{(x-2)^2}{2} \underset{\omega_1}{\underset{\omega_2}{\gtrless}} 0$$

$$\hat{R}_1 = (-\infty, 3 - \sqrt{3}] \cup [3 + \sqrt{3}, \infty)$$
$$= (-\infty, 1.27] \cup [4.73, \infty)$$



# Bayesov rizik (primer)

- Neka je potrebno izvršiti klasifikaciju u dve klase za koje su raspodele obeležja date sledećim izrazima:

$$p(\mathbf{x} | \omega_1) = \frac{1}{\sqrt{2\pi}\sqrt{3}} e^{-\frac{x^2}{6}}, \quad p(\mathbf{x} | \omega_2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-2)^2}{2}}.$$

Skicirati raspodele obeležja i, uz pretpostavku da je  $P(\omega_1) = P(\omega_2) = 0.5$ ,  $C_{11} = C_{22} = 0$ ,  $C_{12} = 1$  i  $C_{21} = \sqrt{3}$ , odrediti pravilo odlučivanja koje minimizuje Bayesov rizik.


- Rešenje:

$$\Lambda(x) = \frac{\frac{1}{\sqrt{2\pi}\sqrt{3}} e^{-\frac{x^2}{6}}}{\frac{1}{\sqrt{2\pi}} e^{-\frac{(x-2)^2}{2}}} = \frac{1}{\sqrt{3}} e^{-\frac{x^2}{6} + \frac{(x-2)^2}{2}} \underset{\omega_1}{\geq} \underset{\omega_2}{\frac{1}{\sqrt{3}}}$$

$$-\frac{x^2}{6} + \frac{(x-2)^2}{2} \underset{\omega_1}{\geq} \underset{\omega_2}{0}$$

$$\hat{R}_1 = (-\infty, 3 - \sqrt{3}] \cup [3 + \sqrt{3}, \infty)$$

$$= (-\infty, 1.27] \cup [4.73, \infty)$$



# Rezime

- Pravilo odlučivanja zasnovano na LR testu koje minimizuje Bayesov rizik često se naziva *Bayesov kriterijum*:

$$\Lambda(\mathbf{x}) = \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \underset{\omega_2}{\overset{\omega_1}{\gtrless}} \frac{(C_{12} - C_{22})}{(C_{21} - C_{11})} \cdot \frac{P(\omega_2)}{P(\omega_1)}$$

**Bayesov kriterijum**

- Ako je cilj minimizovati verovatnoću greške, to je specijalan slučaj Bayesovog kriterijuma kada su cene simetrične i jednake 0 ili 1. Ova varijanta pravila odlučivanja zasnovanog na LR testu naziva se kriterijum *maksimalne aposteriorne verovatnoće* (MAP kriterijum)

$$C_{ij} = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases} \quad \Lambda(\mathbf{x}) = \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \underset{\omega_2}{\overset{\omega_1}{\gtrless}} \frac{P(\omega_2)}{P(\omega_1)} \Leftrightarrow \frac{P(\omega_1 | \mathbf{x})}{P(\omega_2 | \mathbf{x})} \underset{\omega_2}{\overset{\omega_1}{\gtrless}} 1$$

**MAP kriterijum**

- Ako su pri tome i apriorne verovatnoće jednake,  $P(\omega_1) = P(\omega_2) = 1/2$ , pravilo odlučivanja zasnovano na LR testu se svodi na *kriterijum maksimalne izglednosti* (ML kriterijum), koji maksimizuje izglednost  $P(\mathbf{x} | \omega_i)$

$$C_{ij} = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases} \wedge P(\omega_1) = P(\omega_2) = 1/2 \quad \Lambda(\mathbf{x}) = \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \underset{\omega_2}{\overset{\omega_1}{\gtrless}} 1$$

**ML kriterijum**

# Još neke varijante LR testa

## ■ Neyman-Pearsonov kriterijum

- Maksimalna verovatnoća greške za jednu klasu se fiksira na određenu vrednost, nakon čega se minimizuje verovatnoća greške za drugu klasu
  - Kod binarne klasifikacije obično se fiksira verovatnoća lažnog pozitivnog rezultata (npr. pri detekciji radarom), ali ima i drugih okolnosti kada je ovaj pristup pogodan
    - Npr. u problemu klasifikacije ribe, moguće je da postoji propis kojim se zabranjuje da više od 1% lososa bude klasifikovano kao brancin
  - NP kriterijum je veoma popularan pošto ne zahteva predznanje o apriornim verovatnoćama pojedinih klasa niti cenama

## ■ *Minimax* kriterijum

- Zasniva se na minimizaciji gornjeg ograničenja Bayesovog rizika (Bayesovog rizika u najgorem slučaju) i često se koristi u teoriji igara
  - *Minimax* kriterijum ne zahteva poznavanje apriornih verovatnoća pojedinih klasa, ali se cene moraju definisati
  - Pogodan u slučajevima kada apriorne verovatnoće mogu varirati




# Minimizacija verovatnoće greške za više od dve klase

- Verovatnoća tačne klasifikacije iznosi:

$$\begin{aligned} P(\text{tačno}) &= 1 - P(\text{greška}) = \sum_{i=1}^K P(\omega_i) \int_{R_i} p(\mathbf{x} | \omega_i) d\mathbf{x} \\ &= \sum_{i=1}^K \int_{R_i} P(\omega_i) p(\mathbf{x} | \omega_i) d\mathbf{x} = \sum_{i=1}^K \underbrace{\int_{R_i} p(\mathbf{x}) P(\omega_i | \mathbf{x}) d\mathbf{x}}_{I_i} \end{aligned}$$

- Maksimizacija  $P(\text{tačno})$  podrazumeva maksimizaciju svakog integrala  $I_i$ , tako da za svako  $\mathbf{x}$  treba odabrati klasu za koju je  $P(\omega_i | \mathbf{x})$  maksimalno (odnosno,  $R_i$  treba definisati kao region u kom je  $P(\omega_i | \mathbf{x})$  maksimalno)
- Dakle, i u slučaju više od dve klase, MAP kriterijum minimizuje verovatnoću greške



# Minimizacija Bayesovog rizika za više od dve klase

- Pravilo odlučivanja koje minimizuje Bayesov rizik za dve klase može se jednostavno uopštiti i na slučaj sa tri ili više klasa

$$\begin{aligned}\mathfrak{R} = E[C] &= \sum_{i=1}^K \sum_{j=1}^K C_{ij} \cdot P(\text{odabrano } \omega_i \text{ a stvarna klasa je } \omega_j) \\ &= \sum_{i=1}^K \sum_{j=1}^K C_{ij} \cdot P(\mathbf{x} \in R_i | \omega_j) P(\omega_j) \\ &= \sum_{i=1}^K \sum_{j=1}^K C_{ij} \cdot P(\omega_j) \int_{R_i} p(\mathbf{x} | \omega_j) d\mathbf{x} \\ &= \sum_{i=1}^K \int_{R_i} \sum_{j=1}^K C_{ij} \cdot P(\omega_j) p(\mathbf{x} | \omega_j) d\mathbf{x}\end{aligned}$$

- Minimizacija  $\mathfrak{R}$  postiže se minimizacijom svakog integrala pojedinačno, što znači da  $R_i$  treba birati tako da bude:

$$\mathbf{x} \in R_i \Leftrightarrow \sum_{j=1}^K C_{ij} \cdot P(\omega_j) p(\mathbf{x} | \omega_j) < \sum_{j=1}^K C_{kj} \cdot P(\omega_j) p(\mathbf{x} | \omega_j), \forall k \neq i$$

što se ponovo svodi na LR test, odnosno, uzorak  $\mathbf{x}$  će se smestiti u klasu  $\omega_i$  ako važi:

$$\frac{p(\mathbf{x} | \omega_i)}{p(\mathbf{x} | \omega_j)} > \frac{(C_{ij} - C_{jj})}{(C_{ji} - C_{ii})} \cdot \frac{P(\omega_j)}{P(\omega_i)}, \quad \forall j \neq i$$


# Minimizacija Bayesovog rizika za više od dve klase

## ■ Moguća je i alternativna formulacija

- Neka je  $\alpha_i$  odluka da se uzorak  $\mathbf{x}$  klasifikuje u klasu  $\omega_i$
- Rizik (prosečna cena) te odluke jednak je:

$$\mathfrak{R}(\alpha_i | \mathbf{x}) = \sum_{j=1}^K C_{ij} \cdot P(\omega_j | \mathbf{x})$$

- Za svako  $\mathbf{x}$  treba odabrati ono  $\omega_i$  koje daje najmanje  $\mathfrak{R}(\alpha_i | \mathbf{x})$ , tj. minimalni rizik klasifikacije u  $\omega_i$



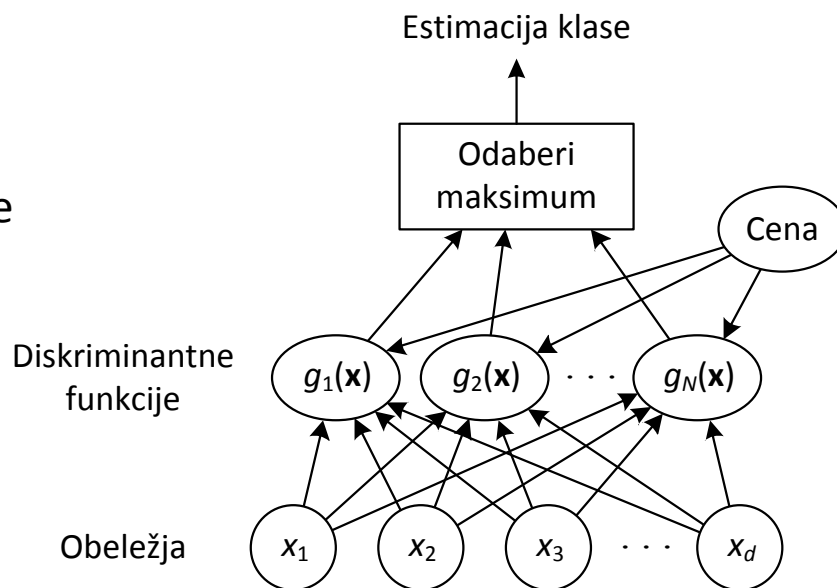
# Diskriminantne funkcije

- Sva dosad prikazana pravila odlučivanja imaju istu strukturu
  - U svakoj tački  $\mathbf{x}$  prostora obeležja bira se klasa  $\omega_i$  koja maksimizuje (ili minimizuje) neku meru  $g_i(\mathbf{x})$ , koju nazivamo *diskriminantna funkcija*
  - Pravilo odlučivanja u tom slučaju glasi:

„dodeli  $\mathbf{x}$  klasi  $\omega_i$  ako je  $g_i(\mathbf{x}) \geq g_j(\mathbf{x})$  za svako  $j \neq i$ “

odnosno, svodi se na poređenje diskriminantata za različite klase

- U nekim slučajevima diskriminante se mogu svesti na jednostavne izraze
- Ista monotona transformacija svih diskriminantnih funkcija ne utiče na rezultat, npr:
  - dodavanje konstante
  - logaritmovanje



# Diskriminantne funkcije

- Tri osnovna pravila odlučivanja mogu se predstaviti preko diskriminantnih funkcija na sledeći način:

Kriterijum	Diskriminantna funkcija
Bayesov	$g_i(\mathbf{x}) = -\mathcal{R}(\alpha_i   \mathbf{x})$
MAP	$g_i(\mathbf{x}) = P(\omega_i   \mathbf{x})$
ML	$g_i(\mathbf{x}) = p(\mathbf{x}   \omega_i)$

- Bayesova teorija odlučivanja daje dobru teorijsku osnovu za klasifikaciju
  - U praksi apriorne verovatnoće pojedinih klasa, kao ni raspodele obeležja unutar tih klasa, **nisu poznate**, već ih je potrebno proceniti
  - Mnogi klasifikatori radije direktno određuju granice odlučivanja, koje su u opštem slučaju suboptimalne u odnosu na Bayesove klasifikatore
    - Linearne diskriminantne funkcije, perceptroni, vektori nosači, neuralne mreže...