

Linearna klasifikacija i perceptronsko učenje

- Linearna klasifikacija
 - Geometrijska interpretacija linearne klasifikacije
 - Perceptronsko učenje


Jednačine prave i ravni (podsećanje)

Jednačina prave u ravni (2D)

$$w_1x_1 + w_2x_2 + w_0 = 0$$

$$\mathbf{w}^T \mathbf{x} + w_0 = 0$$

$$d = \frac{|w_0|}{\sqrt{w_1^2 + w_2^2}} = \frac{|w_0|}{\|\mathbf{w}\|}$$



Rastojanje proizvoljne tačke \mathbf{x}' od prave $\mathbf{w}^T \mathbf{x} + w_0 = 0$:


$$r = \frac{|\mathbf{w}^T \mathbf{x}' + w_0|}{\sqrt{w_1^2 + w_2^2}} = \frac{|\mathbf{w}^T \mathbf{x}' + w_0|}{\|\mathbf{w}\|}$$

Jednačina ravni u prostoru (3D)

$$w_1x_1 + w_2x_2 + w_3x_3 + w_0 = 0$$

$$\mathbf{w}^T \mathbf{x} + w_0 = 0$$

$$d = \frac{|w_0|}{\sqrt{w_1^2 + w_2^2 + w_3^2}} = \frac{|w_0|}{\|\mathbf{w}\|}$$



Rastojanje proizvoljne tačke \mathbf{x}' od ravni $\mathbf{w}^T \mathbf{x} + w_0 = 0$:

$$r = \frac{|\mathbf{w}^T \mathbf{x}' + w_0|}{\sqrt{w_1^2 + w_2^2 + w_3^2}} = \frac{|\mathbf{w}^T \mathbf{x}' + w_0|}{\|\mathbf{w}\|}$$

Linearna klasifikacija

- Linearna klasifikacija u dve klase može se realizovati na osnovu linearne regresije tako što nepoznati uzorak dodeljujemo jednoj ili drugoj klasi u zavisnosti od toga da li je vrednost izlazne veličine pozitivna ili negativna

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0, \quad g(\mathbf{x}) \underset{\omega_2}{\overset{\omega_1}{\gtrless}} 0$$

- Uzorci dveju klasa su *linearno razdvojivi* ako postoji hiperravan $g(\mathbf{x}) = 0$ koja predstavlja granicu odlučivanja između njih
- Ako su \mathbf{x}_1 i \mathbf{x}_2 dve tačke na hiperravni odlučivanja, važi sledeće:


$$\mathbf{w}^T \mathbf{x}_1 + w_0 = \mathbf{w}^T \mathbf{x}_2 + w_0 = 0,$$

odakle se dobija:

$$\mathbf{w}^T (\mathbf{x}_1 - \mathbf{x}_2) = 0,$$



što znači da je vektor \mathbf{w} *ortogonalan* na hiperravan odlučivanja

- Količnik $\frac{|g(\mathbf{x})|}{\|\mathbf{w}\|}$ predstavlja euklidsko rastojanje tačke \mathbf{x} od hiperravni odlučivanja



Perceptron

- Jednostavan koncept mašine za učenje namenjene rešavanju problema linearne klasifikacije
 - Perceptron izračunava skalarnu funkciju više ulaznih promenljivih x_i pomnoženih težinskim faktorima w_i
 - U slučaju binarne klasifikacije, uzorak se klasifikuje u jednu od dve klase na osnovu znaka izlaza, što se može predstaviti step-funkcijom sa izlazima $y = \pm 1$
 - Perceptron je u stanju da automatski formira model, odnosno, odredi vrednosti težinskih koeficijenata \mathbf{w} na osnovu uzoraka, koristeći određeni *algoritam učenja*
- Perceptron se često nadograđuje tako što se umesto step-funkcije na izlazu uvede neka druga, po pravilu neprekidna nelinearna funkcija
 - Ovako modifikovan perceptron naziva se *neuron* i predstavlja osnovu veštačkih neuronskih mreža
 - Pošto izlaz predstavlja nelinearnu funkciju linearne kombinacije ulaznih promenljivih (često sigmoid, i u tom slučaju je zapravo reč o *logističkoj regresiji*)



Perceptronsko učenje (problem dve klase)


- Neka skup za obuku $\mathbf{X} = \{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}\}$ sadrži uzorke koji pripadaju klasama ω_1 i ω_2 i neka važi pretpostavka njihove linearne razdvojivosti
 - Prag w_0 podvodi se pod težinski vektor \mathbf{w} uvođenjem pomoćnog obeležja $x_0 = 1$ (nadalje će se smatrati da je $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$, pri čemu vektor \mathbf{x} sadrži i obeležje x_0)

Zadatak perceptronskog učenja:

Naći vektor \mathbf{w} takav da važi:

$$\mathbf{w}^T \mathbf{x} > 0, \forall \mathbf{x} \in \omega_1$$

$$\mathbf{w}^T \mathbf{x} < 0, \forall \mathbf{x} \in \omega_2$$



- Ako se uvedu oznake klasa $y_1 = 1$ za klasu ω_1 i $y_2 = -1$ za klasu ω_2 , problem se svodi na nalaženje vektora \mathbf{w} takvog da $y^{(i)} \cdot \mathbf{w}^T \mathbf{x}^{(i)} > 0, \forall \mathbf{x}^{(i)}$
 - Ovo je ekvivalentno promeni znaka svih uzoraka iz klase ω_2 ($\mathbf{x} \leftarrow [-\mathbf{x}], \forall \mathbf{x} \in \omega_2$) nakon čega je dovoljno naći vektor \mathbf{w} takav da $\mathbf{w}^T \mathbf{x} > 0, \forall \mathbf{x}$ (oznake klasa mogu se ignorisati)

Napomena: Uvođenje obeležja x_0 koje je uvek jednako 1 značajno komplikuje geometrijsku interpretaciju jer povećava dimenzionalnost problema za 1. Konkretno, u datom primeru i vektor \mathbf{x} i vektor \mathbf{w} zapravo su trodimenzionalni, pa se situacija više ne može adekvatno predstaviti u samo dve dimenzije.

Perceptronsko učenje (problem dve klase)

- Sada treba naći pogodnu funkciju greške $J(\mathbf{w})$ koju treba minimizovati
 - $J(\mathbf{w})$ treba da predstavlja meru greške klasifikacije na osnovu proizvoljne hiperravni \mathbf{w}
 - $J(\mathbf{w})$ treba da ima vrednost 0 ako su svi uzorci ispravno klasifikovani, a treba da bude tim veća što je više pogrešno klasifikovanih uzoraka i što su pogrešno klasifikovani uzorci udaljeniji od hiperravni \mathbf{w}
- Nakon promene znaka uzorcima iz klase ω_2 , čime je uslov sveden na $\mathbf{w}^T \mathbf{x} > 0, \forall \mathbf{x}$, za funkciju greške može se usvojiti tzv. perceptronska kriterijumska funkcija:

$$J_p(\mathbf{w}) = \sum_{\mathbf{x} \in X_M} (-\mathbf{w}^T \mathbf{x}),$$

gde je X_M skup uzoraka pogrešno klasifikovanih pomoću \mathbf{w}

- $J_p(\mathbf{w})$ je jednaka 0 kada su svi uzorci ispravno klasifikovani, jer je tada $X_M = \emptyset$
- U ostalim slučajevima $J_p(\mathbf{w})$ je pozitivna jer za pogrešno klasifikovane uzorke važi $\mathbf{w}^T \mathbf{x} < 0$
- $J_p(\mathbf{w})$ se minimizuje metodom gradijentnog silaska
 - Ako su uzorci linearno separabilni, algoritam gradijentnog silaska dolazi do rešenja u konačno mnogo koraka

Perceptronsko učenje (problem dve klase)

- Gradijent perceptronske kriterijumske funkcije jednak je:

$$\nabla_{\mathbf{w}} J_P(\mathbf{w}) = \nabla_{\mathbf{w}} \sum_{\mathbf{x} \in X_M} (-\mathbf{w}^T \mathbf{x}) = \sum_{\mathbf{x} \in X_M} (-\mathbf{x})$$

pa se vrednost \mathbf{w} po metodi gradijentnog silaska obnavlja po pravilu:

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \alpha \nabla_{\mathbf{w}} J_P(\mathbf{w}(k)) = \mathbf{w}(k) + \alpha \sum_{\mathbf{x} \in X_M} \mathbf{x}$$

- Ovo pravilo poznato je kao *grupno perceptronsko pravilo ažuriranja*
 - U obnavljanju vrednosti \mathbf{w} učestvuju svi pogrešno klasifikovani uzorci, odnosno, njihova suma

- Početi od proizvoljne vrednosti $\mathbf{w}(0)$
- Odrediti skup pogrešno klasifikovanih uzoraka X_M za dato $\mathbf{w}(k)$, a zatim korigovati vektor $\mathbf{w}(k)$:

$$\mathbf{w}(k+1) = \mathbf{w}(k) - \alpha \nabla_{\mathbf{w}} J_P(\mathbf{w}(k)) = \mathbf{w}(k) + \alpha \sum_{\mathbf{x} \in X_M} \mathbf{x}$$

gde je α brzina učenja (fiksni mali broj)

- Ponavljati prethodni korak do ispravne klasifikacije svih uzoraka (dok ne bude $X_M = \emptyset$)

Perceptronsko učenje (problem dve klase)

- Težinski vektor \mathbf{w} može obnavljati vrednost i na osnovu pojedinačnih uzoraka, i u tom slučaju uzorci $\mathbf{x}^{(i)}$ ulaze u algoritam jedan za drugim, najbolje slučajnim redosledom
 - Ako algoritam nije konvergirao nakon obrade svih uzoraka jednom, procedura se ponavlja dok se ne dostigne konvergencija (do ispravne klasifikacije svih uzoraka)
 - Perceptronsko pravilo ažuriranja svodi se na:


$$\mathbf{w}(k+1) = \mathbf{w}(k) + \alpha \mathbf{x}^{(k)}$$

gde je $\mathbf{x}^{(k)}$ neki od uzoraka koji su u k -tom koraku bili pogrešno klasifikovani pomoću $\mathbf{w}(k)$

- Ako su klase linearno razdvojive, obe verzije perceptronskog učenja (grupna i pojedinačna) konvergiraju ka ispravnom rešenju u konačno mnogo koraka
- Ako klase nisu linearno razdvojive, perceptronsko učenje neće konvergirati
 - Nijedan težinski vektor \mathbf{w} ne može ispravno klasifikovati *svaki* uzorak, pa će nakon svakog koraka algoritma ponovo biti pogrešno klasifikovanih uzoraka, a samim tim i novih promena
 - Jedno rešenje je u usvajanju promenljive brzine učenja $\alpha(k)$ koja teži ka 0 kada $k \rightarrow \infty$
 - Varijanta algoritma koja sprečava oscilovanje između različitih rešenja bez mogućnosti zaustavljanja naziva se *algoritam džepa*
 - Ideja je da algoritam tokom iterativnog procesa pamti „u džepu“ najbolje rešenje koje je pronađeno do datog trenutka i ažurira ga samo ako se pojavi bolje rešenje
 - Pod određenim uslovima algoritam džepa konvergira ka suboptimalnom rešenju, odnosno, dolazi do minimalnog broja pogrešnih klasifikacija

Klasifikacija u više od dve klase

- U praksi retko postoji linearna separabilnost između više klasa, tako da se linearna klasifikacija u više klasa uglavnom i ne radi pomoću perceptrona
 - U opštem slučaju, klasifikacija u više od dve klase ($\omega_1, \omega_2, \dots, \omega_K$) može se uvek realizovati kao višestruka primena klasifikacije u dve klase:
 - $\omega_1/\text{ne } \omega_1; \omega_2/\text{ne } \omega_2; \dots; \omega_K/\text{ne } \omega_K$ (eng. *one versus rest* – OVR)
 - ω_i/ω_j za svako i i j (eng. *one versus one* – OVO)
- a zatim odlučivanjem po većinskom principu, ali se pokazuje da oba načina imaju nedostatke (mogu se javiti sporni regioni nedefinisane pripadnosti)



Klasifikacija u više od dve klase

- Pristup „jedan protiv svih“ (OVR) u praksi se modifikuje tako da se klasifikacija u više klasa vrši na osnovu diskriminantnih funkcija, čime se prevazilazi problem spornih regiona nedefinisane pripadnosti
 - Ponovo se svakoj klasi ω_i pridružuje po jedan perceptron, čiji se težinski vektor \mathbf{w}_i određuje perceptronskim učenjem na klasama ω_i i „ne ω_i “, pri čemu taj vektor ujedno određuje i odgovarajuću diskriminantnu funkciju $g_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_0$
 - Odlučivanje se ne vrši većinski, već klasifikator dodeljuje uzorak opisan vektorom obeležja \mathbf{x} klasi ω_i ako je $g_i(\mathbf{x}) > g_j(\mathbf{x})$ za svako $j \neq i$, odnosno, uzorak se dodeljuje klasi čiji je perceptron dao najveći *odziv* na \mathbf{x}
 - Pošto su diskriminantne funkcije linearne, površi odlučivanja predstavljaju hiperravni

