

# Metode na bazi vektora nosača

- Metode na bazi vektora nosača
  - Klasifikator maksimalne margine (linearno razdvojiv slučaj)
    - Matematički model i interpretacija pojma vektora nosača
    - Ograničenja klasifikatora maksimalne margine
  - Klasifikator blage margine (linearno nerazdvojiv slučaj)
    - Modifikacija matematičkog modela
    - Potreba za daljim proširenjem
  - Mašine na bazi vektora nosača (eng. *Support Vector Machines* – SVM)
    - Preslikavanje problema u višedimenzionalni prostor

# Metode na bazi vektora nosača (uvod)


- Pristup rešavanju problema binarne klasifikacije pronalaženjem hiperravni koja razdvaja uzorke različitih klasa u prostoru obeležja
- Osnovna ideja ovog pristupa bazira se na **klasifikatoru maksimalne margine**
  - Ovaj klasifikator, iako vrlo elegantan i jednostavan, primenljiv je samo u slučaju kada su uzorci dveju klasa linearno razdvojivi
  - Ako uzorci nisu linearno razdvojivi, može se ići u dva pravca:
    - Ne zahtevati striktno razdvajanje svih uzoraka već samo razdvajanje u što većoj meri
    - Preslikati problem u prostor više dimenzionalnosti u kom će uzorci biti barem približno linearno razdvojivi
- **Klasifikator blage margine** predstavlja proširenje klasifikatora maksimalne margine, primenljivo u slučaju kada su uzorci barem približno linearno razdvojivi
- **Mašine na bazi vektora nosača** (eng. *support vector machines* – *SVM*) predstavljaju dalje proširenje, kojim se mogu modelovati i nelinearne granice odlučivanja

# Klasifikator maksimalne margine

- Hiperravan u  $d$  dimenzija predstavlja ravan afini potprostor dimenzije  $d-1$ :

$$\vartheta_0 + \vartheta_1 x_1 + \vartheta_2 x_2 + \dots + \vartheta_d x_d = 0$$

- Tačke za koje je dati zbir pozitivan nalaze se sa jedne strane hiperravni a tačke gde je on negativan sa druge strane
- Ako je  $\vartheta_0 = 0$ , hiperravan prolazi kroz koordinatni početak, inače ne
- Vektor  $\boldsymbol{\theta} = [\vartheta_1 \ \vartheta_2 \ \dots \ \vartheta_d]^T$  ortogonalan je na hiperravan
- Hiperravan u 2D prostoru (u ravni) je prava





- Za problem binarne klasifikacije, hiperravan odlučivanja je hiperravan za koju važi:

- za sve uzorke jedne klase  $\vartheta_0 + \boldsymbol{\theta}^T \mathbf{x} < 0$
- za sve uzorke druge klase  $\vartheta_0 + \boldsymbol{\theta}^T \mathbf{x} > 0$

- Hiperravan koja razdvaja uzorke pojedinih klasa ne mora postojati, a ako postoji, obično nije jedinstvena


- Može se, međutim, uočiti hiperravan koja u najvećoj meri (sa najvećom marginom) razdvaja uzorke

- Udaljenost novog uzorka od te hiperravni u vezi je s pouzdanošću odluke




# Klasifikator maksimalne margine

- *Margina*  $M$  je najmanje rastojanje od hiperravni odlučivanja do bilo kog uzorka iz skupa za obuku
- Vektori koji odgovaraju uzorcima na rastojanju  $M$  od hiperravni odlučivanja predstavljaju „vektore nosače“
  - pomeranje vektora nosača u opštem slučaju izazvalo bi i pomeranje hiperravni odlučivanja
  - relativno mali pomeraji ostalih uzoraka iz skupa za obuku nemaju nikakav uticaj
- Klasifikator maksimalne margine dobija se kao rešenje optimizacionog problema:
  - Maksimizovati  $M$  u odnosu na  $\theta$  pod ograničenjima:
    - $\sum_{j=0}^d \vartheta_j^2 = 1$  (samo radi jedinstvenosti jednačine hiperravni)
    - $y_i \cdot (\vartheta_0 + \vartheta_1 x_1^{(i)} + \dots + \vartheta_d x_d^{(i)}) \geq M, \quad \forall i = 1, 2, \dots, N$  ( $y_i = \pm 1$  zavisno od klase)
- Dati optimizacioni problem može se rešiti korišćenjem Lagrangeovih multiplikatora, i hiperravan odlučivanja dobijena na ovaj način je jedinstvena
  - Vektor  $\theta$  dobija se kao linearna kombinacija vektora nosača



# Ograničenja klasifikatora maksimalne margine


- Metod je neprimenljiv ako uzorci nisu linearno razdvojivi
- Položaj hiperravni odlučivanja je veoma osetljiv na položaj pojedinačnih uzoraka
  - Primera radi, uvođenje samo jednog novog uzorka može drastično promeniti procenjeni položaj hiperravni odlučivanja



- Ovo ukazuje na to da je, u nekom smislu, nastupilo natprilagođenje (*overfitting*)
- Generalno, dobijena procena, iako je možda dobro centrirana, ima izuzetno visoku varijansu
- Treba dozvoliti mogućnost da poneki uzorak za obuku ne bude dobro klasifikovan
  - Na račun toga bio bi dobijen klasifikator koji je mnogo robustniji na pojedinačne uzorke

# Klasifikator blage margine


- Dozvoljava da poneki uzorak iz skupa za obuku bude sa pogrešne strane marginalne hiperravnini, pa i sa pogrešne strane hiperravnini odlučivanja
  - Ako uzorci nisu linearno razdvojivi, ovo poslednje je i neizbežno
- Ovako definisan klasifikator dobija se kao rešenje optimizacionog problema:
  - Maksimizovati  $M$  u odnosu na  $\theta$  i  $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N$  pod ograničenjima:
    - $\sum_{j=0}^d \vartheta_j^2 = 1$
    - $y_i \cdot (\vartheta_0 + \vartheta_1 x_1^{(i)} + \dots + \vartheta_d x_d^{(i)}) \geq M(1 - \varepsilon_i) \quad (y_i = \pm 1 \text{ zavisno od klase})$
    - $\varepsilon_i > 0, \quad \sum_{i=1}^N \varepsilon_i \leq C$
  - Ovde su  $\varepsilon_i$  pomoćne promenljive, koje se odnose na to koliko koji uzorak zalazi na pogrešnu stranu marginalne hiperravnini (ili, za  $\varepsilon_i > 1$ , čak i na pogrešnu stranu hiperravnini odlučivanja), dok je  $C$  regularizacioni hiperparametar, koji se može posmatrati kao „budžet“ za ukupno odstupanje  $\varepsilon_i$ 
    - Ovaj problem matematički nije ništa složeniji od prethodnog
    - $C$  se u praksi određuje unakrsnom validacijom






# Klasifikator blage margine

- Na položaj hiperravni odlučivanja sada utiču samo uzorci koji se nalaze na marginalnoj hiperravni ili s njene pogrešne strane (to su sada vektori nosači)
  - Metoda vektora nosača, za razliku od mnogih drugih, uopšte ne uzima u obzir položaje uzoraka koji su daleko od granice odlučivanja (a sa njene prave strane)
- Kao i u slučaju klasifikatora maksimalne margine, vektor  $\theta$  dobija se kao linearna kombinacija vektora nosača, čiji broj s porastom  $C$  raste\*

veliko  $C$




malo  $C$



\*u literaturi ima i drugačijih formulacija optimizacionog problema, kod kojih se regularizacioni parametar  $C$  uvodi na drugačiji način, takav da sa porastom  $C$  broj vektora nosača *opada*

# Ograničenja klasifikatora blage margine


- Postoje situacije kada linearne granice odlučivanja, bez obzira na vrednost  $C$ , nisu odgovarajuće
- Moguće je proširiti prostor obeležja nelinearnim članovima, odnosno, umesto  $d$  obeležja  $x_1, x_2, \dots, x_d$  koristiti npr.  $2d$  obeležja  $x_1, x_2, \dots, x_d, x_1^2, x_2^2, \dots, x_d^2$
- Ovako redefinisanom problemu odgovarale bi linearne granice odlučivanja u proširenom prostoru, ali nelinearne u originalnom, jer bi ograničenja bila:
  - $y_i \cdot (\vartheta_0 + \sum_{j=1}^d \vartheta_{j1} x_j^{(i)} + \sum_{j=1}^d \vartheta_{j2} (x_j^{(i)})^2) \geq M(1 - \varepsilon_i)$
  - $\varepsilon_i > 0, \sum_{i=1}^N \varepsilon_i \leq C, \vartheta_0 + \sum_{j=1}^d (\vartheta_{j1}^2 + \vartheta_{j2}^2) = 1$
- Ovo je i bilo potrebno postići, ali prelazak u višedimenzionalni prostor pogoršava problem manjka podataka, a povećava se i računaska složenost
  - Zbog toga je potrebno dobro osmisлити način uvođenja ove nelinearnosti





# Mašine na bazi vektora nosača

- Problem konstrukcije nelinearnih granica odlučivanja rešava se u dve etape
  - Nelinearno preslikavanje uzoraka u višedimenzionalni prostor ( $\mathbf{z} = \varphi(\mathbf{x})$ )
  - Konstrukcija optimalne hiperravni odlučivanja u tom višedimenzionalnom prostoru
- Primer:
  - Slika levo ilustruje uzorke u 2D prostoru kod kojih nije moguće konstruisati hiperravan odlučivanja koja bi dala zadovoljavajuće rezultate
  - Uvođenjem preslikavanja  $\mathbf{z} = \varphi(\mathbf{x})$  u 3D prostor prema sledećem pravilu:
$$\mathbf{x} = (x_1, x_2) \rightarrow \mathbf{z} = (z_1, z_2, z_3) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$
obezbeđuje se linearna razdvojivost u 3D prostoru (slika desno)



- Optimalnoj hiperravni odlučivanja u visokodimenzionalnom prostoru odgovara optimalna nelinearna granica odlučivanja u polaznom

# Kernel funkcije

- Može se pokazati sledeće:
  - U postupku konstrukcije optimalne hiperravni odlučivanja pojedini uzorci figurišu samo u okviru skalarnih proizvoda njihovih parova  $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$
  - Pri klasifikaciji nepoznatog uzorka  $\mathbf{x}'$  ni njegova obeležja u izračunavanju ne učestvuju kao pojedinačna, već samo u okviru skalarnog proizvoda  $\langle \mathbf{x}', \mathbf{x}_i \rangle$  tog uzorka s uzorcima iz skupa za obuku (i to samo sa vektorima nosačima jer ostali ne utiču na hiperravan odlučivanja)
- Ako bi se svaki skalarni proizvod vektora  $\mathbf{x}_i$  i  $\mathbf{x}_j$  u ovim postupcima zamenio funkcijom  $K(\mathbf{x}_i, \mathbf{x}_j)$ , koja izračunava vrednost skalarnog proizvoda transformisanih uzoraka a da pri tome uopšte ne primenjuje eksplicitno preslikavanje, dobili bi se postupci koji obavljaju isti zadatak razdvajanja uzoraka, ali u visokodimenzionalnom prostoru u kom je granica odlučivanja linearna
- Ovakvi klasifikatori nazivaju se mašinama na bazi vektora nosača (eng. *support vector machines* – SVM) i u zavisnosti od problema koriste neku od standardnih kernel funkcija


Polinomijalni kernel stepena  $m > 0$

$$K(\mathbf{x}_i, \mathbf{x}_j) = \left( 1 + \sum_{k=1}^d x_{ik} x_{jk} \right)^m$$


Radijalni kernel

$$K(\mathbf{x}_i, \mathbf{x}_j) = e^{-\gamma \sum_{k=1}^d (x_{ik} - x_{jk})^2}, \gamma > 0$$

Polinomijalni kernel



Radijalni kernel



# Klasifikacija u više od dve klase

- Kao i kod linearne klasifikacije, klasifikacija u više od dve klase ( $\omega_1, \omega_2, \dots, \omega_K$ ) uvek se može realizovati višestrukom primenom klasifikacije u dve klase, ali se to radije izbegava zbog problema regiona nedefinisane pripadnosti
- **Jedan protiv svih** (eng. *one versus rest* – OVR)
  - Konstruiše se  $K$  SVM klasifikatora i svaki od njih se obučava za klasifikaciju u klase  $\omega_i$  i „ne  $\omega_i$ “, i na kraju se uzorak  $\mathbf{x}'$  dodeli onoj klasi  $\omega_i$  koja maksimizuje vrednost izraza koji opisuje nivo pouzdanosti da joj uzorak  $\mathbf{x}'$  pripada (kod linearnih SVM to je  $\boldsymbol{\theta}_i^T \mathbf{x}'$ , a kod nelinearnih se računa na osnovu  $K(\mathbf{x}', \mathbf{x}_i)$ )
  - U ovom slučaju izbegnuta je višestruka primena binarne klasifikacije, pa i problem regiona nedefinisane pripadnosti
- **Svaki protiv svakog** (eng. *one versus one* – OVO)
  - Konstruiše se  $\binom{K}{2}$  SVM klasifikatora (što je razumno dogod  $K$  nije suviše velik broj), svaki od njih se obučava za klasifikaciju u određen par klase  $\omega_i$  i  $\omega_j$ , i na kraju se uzorak  $\mathbf{x}$  dodeli onoj klasi koja je najveći broj puta bila uspešnija u ovom nadmetanju po parovima
  - U ovom slučaju problem regiona nedefinisane pripadnosti i dalje postoji

# Rezime

- Metoda vektora nosača prevazilazi određene probleme i ograničenja koji su postojali kod nekih drugih metoda
  - ❑ Daju dobre rezultate čak i kad je količina podataka relativno mala u odnosu na broj dimenzija, odnosno, obeležja
  - ❑ Rezultati su stabilni i ponovljivi (za razliku npr. od neuronskih mreža, gde ima slučajnosti u izboru težinskih koeficijenata)
  - ❑ Postoji jasna geometrijska interpretacija
  - ❑ Optimalno rešenje uključuje samo vektore nosače, tako da je *retko*
  - ❑ Optimalno rešenje traži se *analitički* i može se naći u polinomijalnom vremenu, pri čemu je prevaziđen problem lokalnih minimuma